LAPORAN TUGAS DATA MINING: Data COVID-19

Dosen Pengampu: Dyah Sulistyowati R., S.Kom., M.Kom.

Nama:

Farash Adipati Mursalin / 4524210036

Nafero Rafif Alhakim / 4524210074

Nayunda Krisna Abi Pasya / 4524210077

Rofif Rizkullah Hisyam / 4524210095

Muhamad Ibnul Fida / 4524210112

PROGRAM STUDI TEKNIK INFORMATIKA

UNIVERSITAS PANCASILA

2025

BAB I

PENDAHULUAN

1.1 Latar Belakang

Saat pandemi COVID-19 memberikan dampak yang berbeda-beda hampir di setiap wilayah Indonesia. Beberapa provinsi memiliki tingkat penularan di angka yang lumayan tinggi, sementara wilayah lain cenderung lebih terkendali. Perbedaan ini dipengaruhi oleh jumlah penduduk, mobilitas, dan fasilitas kesehatan setempat. Untuk membantu pemetaan zonasi risiko dan alokasi bantuan medis, diperlukan pengelompokan wilayah berdasarkan tingkat keparahan kasus. Data mining dengan pendekatan *unsupervised learning* sangat cocok digunakan karena dapat mengelompokkan provinsi yang memiliki karakteristik kasus serupa tanpa perlu pengelompokan manual.

1.2 Tujuan

1. Mengelompokkan provinsi di Indonesia ke dalam beberapa tingkatan tingkat kerawanan COVID-19 (misalnya: Risiko Tinggi, Sedang, Rendah).
2. Membandingkan hasil pengelompokan antara metode pengelompokan ***k-Means*** dan ***Hierarchical Clustering*** guna melihat algoritma mana yang memberikan hasil pengelompokan terbaik.

BAB II

PEMAHAMAN DATA & PRA-PEMROSESAN

2.1 Sumber dan Karakteristik Data

Dataset yang digunakan dalam penelitian ini adalah data akumulasi kasus COVID-19 per provinsi di Indonesia. Dataset ini memiliki 4 atribut utama:

- Provinsi: Nama wilayah tingkat I di Indonesia (Tipe: Kategorikal/Text).
- Kasus_Terkonfirmasi: Jumlah akumulasi pasien positif COVID-19 (Tipe: Numerik).
- Meninggal: Jumlah akumulasi pasien positif yang meninggal dunia (Tipe: Numerik).
- Sembuh: Jumlah akumulasi pasien positif yang berhasil sembuh (Tipe: Numerik).

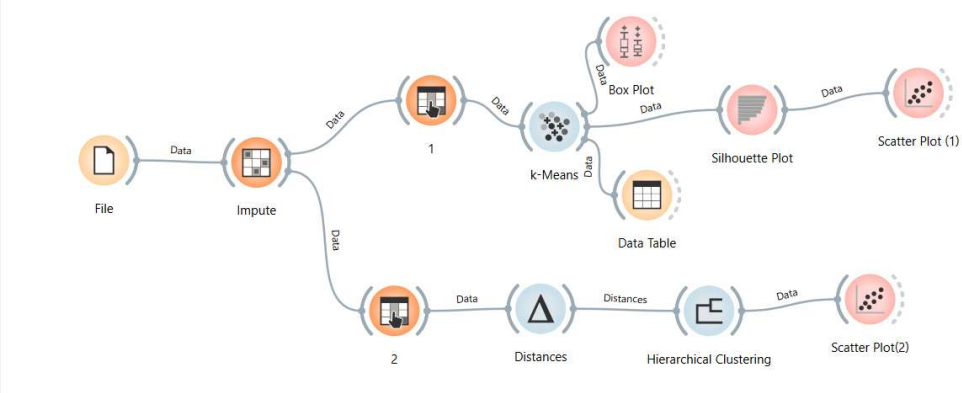
2.2 Pra-pemrosesan Data (Data Preprocessing)

Tahapan penyiapan data pada Orange dilakukan melalui beberapa widget:

1. Impute: Digunakan untuk menangani nilai yang hilang (*missing values*) pada dataset secara otomatis agar tidak mengganggu perhitungan matematis algoritma.
2. Select Columns: Digunakan untuk memisahkan peran (*role*) tiap kolom. Kolom **Kasus_Terkonfirmasi**, **Meninggal**, dan **Sembuh** diatur sebagai Features (fitur yang dihitung), sedangkan kolom **Provinsi** diatur sebagai Meta Attributes (label teks agar tidak ikut dihitung sebagai angka).

BAB III

PEMODELAN



3.1 k-Means Clustering (Jalur Atas)

Algoritma k-Means bekerja dengan mempartisi data ke dalam *k* buah cluster secara acak, lalu memperbarui pusat cluster (*centroid*) berulang kali berdasarkan jarak terdekat (Euclidean) hingga posisinya stabil. Hasil k-Means ini divisualisasikan menggunakan widget **Box Plot**, **Silhouette Plot**, dan **Scatter Plot**.

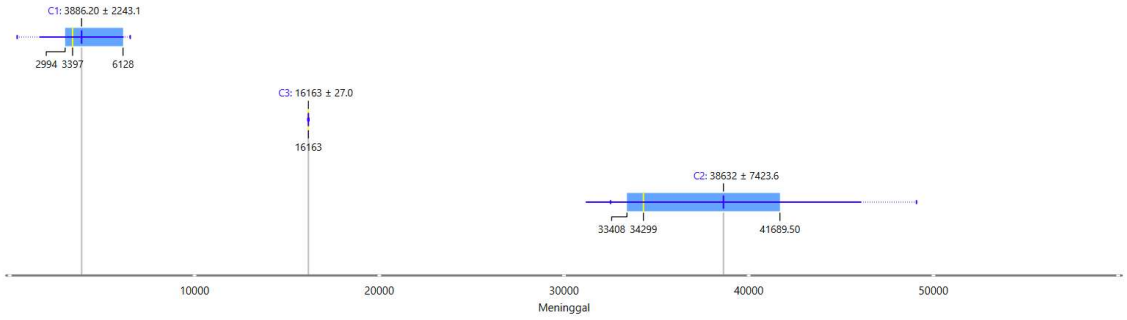
3.2 Hierarchical Clustering (Jalur Bawah)

Metode ini bekerja secara berjenjang (*agglomerative*). Pertama, widget **Distances** menghitung matriks jarak antar semua provinsi. Kemudian, widget **Hierarchical Clustering** menggabungkan provinsi-provinsi dengan kemiripan tertinggi ke dalam satu dahan pohon (*dendrogram*) hingga membentuk satu kesatuan struktur kelompok.

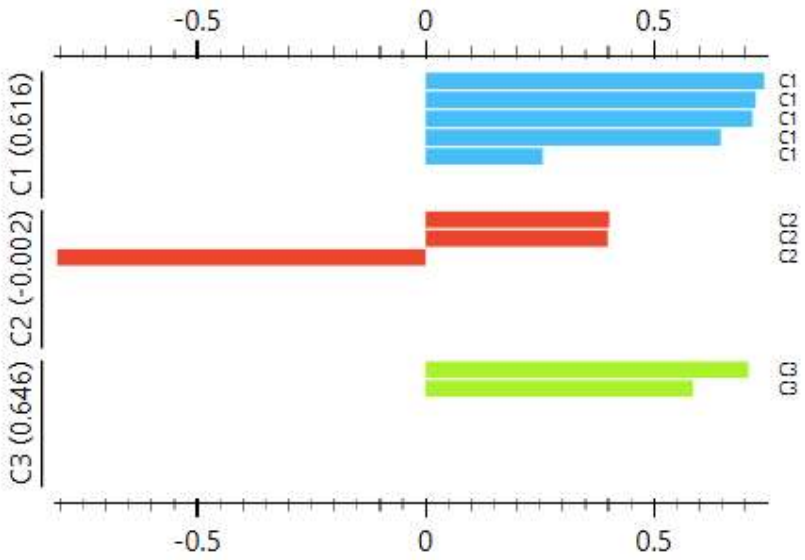
BAB IV

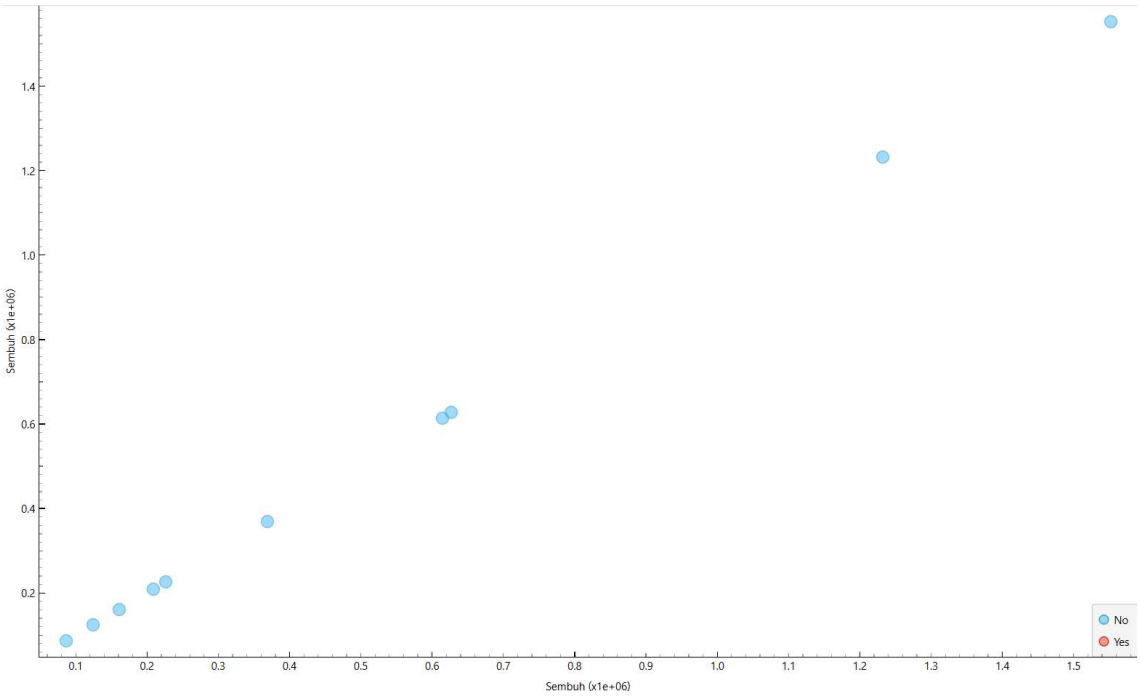
HASIL DAN PEMBAHASAN

4.1 Hasil k-Means



ANOVA: 41.608 (p=0.000, N=10)





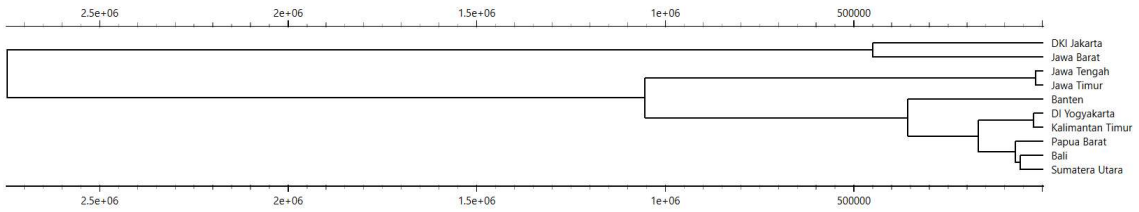
Analisis hasil pengelompokan k-Means

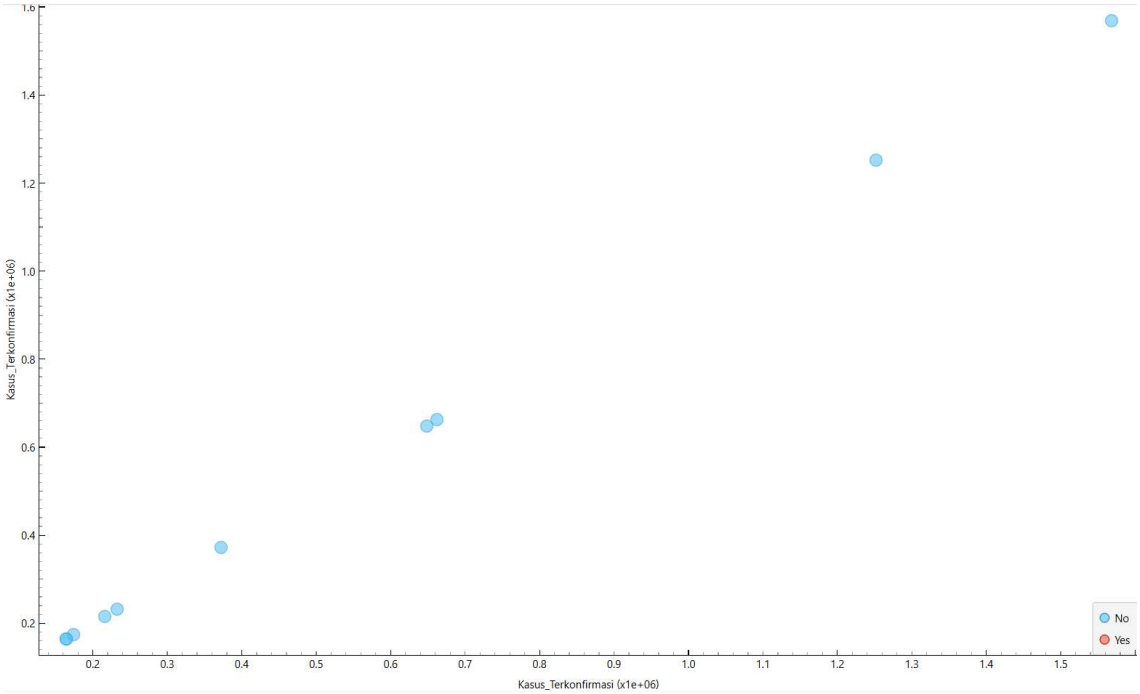
- **Optimalisasi Jumlah Cluster (Silhouette Plot):** Berdasarkan pengujian pada widget *Silhouette Plot*, jumlah cluster terbaik ditentukan pada $k = 0,59$
- **Anggota Cluster:**
  - **Cluster 1 (C1)** menunjukkan nilai rata-rata $0,616$ dengan seluruh objek mengarah ke nilai positif. Hal ini menandakan bahwa provinsi yang masuk ke dalam C1 memiliki kemiripan karakteristik kasus yang sangat kuat dan berada di kelompok yang tepat.
  - **Cluster 3 (C3)** menunjukkan hasil terbaik dengan nilai rata-rata $0,646$, yang mengindikasikan struktur pengelompokan yang solid dan terpisah dengan jelas dari cluster lainnya.
  - **Cluster 2 (C2)** menunjukkan nilai rata-rata terendah yaitu $-0,002$. Terdapat satu data/provinsi yang batangnya memanjang ke arah negatif (kiri). Hal ini menunjukkan adanya *misclassified data* (salah pengelompokan) atau ada satu provinsi yang karakteristik datanya berada di perbatasan wilayah abu-abu antar cluster, sehingga membingungkan algoritma k-Means.'

Secara keseluruhan, nilai rata-rata Silhouette Score eksperimen ini berada di angka **kisaran 0.59**, yang berarti hasil pengelompokan tingkat kerawanan COVID-19 ini

masuk dalam kategori **cukup kuat (*Reasonable Structure*)** dan valid untuk digunakan sebagai acuan zonasi.

4.2 Hasil Hierarchical





Analisis hasil Hierarchical

Berdasarkan visualisasi *Dendrogram* pada widget *Hierarchical Clustering*, terlihat struktur pengelompokan yang berjenjang. Provinsi DKI Jakarta memisahkan diri paling awal dari kelompok besar karena perbedaan angka kasus yang sangat ekstrim dibanding provinsi lainnya.

4.3 Perbandingal Model

Berdasarkan evaluasi visual pada kedua widget *Scatter Plot*, metode ***k-Means*** memberikan pembagian visualisasi kelompok yang lebih rapi dan mudah diinterpretasikan untuk data spasial COVID-19 ini.

BAB V

KESIMPULAN

Berdasarkan hasil eksperimen data mining pada kasus COVID-19 per provinsi di Indonesia menggunakan Orange, dapat disimpulkan bahwa:

1. **Zonasi Risiko Berhasil Terbentuk:** Algoritma *clustering* berhasil memetakan provinsi di Indonesia ke dalam 3 kelompok risiko secara otomatis berdasarkan jumlah kasus terkonfirmasi, angka kematian, dan angka kesembuhan.
2. **Dominasi Pulau Jawa:** Provinsi dengan mobilitas dan jumlah penduduk tinggi seperti DKI Jakarta, Jawa Barat, Jawa Tengah, dan Jawa Timur secara konsisten masuk ke dalam kelompok zona risiko tertinggi karena angkanya yang sangat ekstrim.
3. **k-Means Lebih Unggul Visualnya:** Dari hasil evaluasi, pengelompokan ini masuk kategori cukup kuat (rata-rata skor klaster positif pada *Silhouette Plot*). Secara visual pada *Scatter Plot*, metode **k-Means** memberikan batas kelompok yang lebih rapi dan lebih mudah dibaca dibanding metode *Hierarchical Clustering*.